


# LLM ARTIFICIAL INTELLIGENCE

LOCAL DEPLOYMENT STRATEGY



## Informe Técnico: Estrategia de Implementación de LLM Locales

Proyecto

Ge-mini

Responsable

Daniel Ríos

DRios@datalsia.com

Fecha

20 de abril de 2026

# 1. Auditoría del Entorno Actual

## Hardware & Sistema Operativo

Tras el análisis de las especificaciones del sistema facilitadas, se documenta el entorno base para las pruebas de inferencia local:

### Sistema Operativo

Microsoft Windows 11 Home  
Versión 10.0.26200

### Hardware

Laptop ASUS VivoBook\_ASUSLaptop X431FAC

### CPU

Intel Core i5-10210U @ 1.60GHz  
4 núcleos físicos, 8 hilos

### Memoria RAM

8,00 GB totales  
(7,79 GB utilizables)

### GPU

Gráficos integrados Intel UHD  
Memoria de vídeo compartida

### Virtualización

Hyper-V habilitado  
Soporte para WSL2 y contenedores

 **Diagnóstico de Viabilidad:** Con 8GB de RAM total (y ~1,36GB disponibles según monitor de sistema), la ejecución de modelos de 7B/8B requiere una cuantización agresiva (4-bit o inferior) para evitar el colapso de la memoria del sistema. Se priorizarán modelos de escala **2B-4B** para garantizar estabilidad.


## 2. Herramientas Base Seleccionadas

Para cumplir con la parte de instalación estabilización de herramientas, se han seleccionado las siguientes plataformas:



### A. Ollama — Backend de Inferencia

- **Perfil:** Motor de inferencia ligero que se ejecuta como servicio.
- **Propósito:** Exponer el modelo local a la aplicación Ge-mini mediante una API interna (localhost:11434).
- **Impacto:** Permite *vibe coding* sin necesidad de conexión a internet o APIs externas.



### B. LM Studio — Entorno de Test y Tuning

- **Perfil:** Interfaz visual para descargar y probar modelos de Hugging Face.
- **Propósito:** Realizar pruebas de latencia y ajuste de parámetros (temperatura, contexto) antes de pasar a producción.

# 3. Plan de Pruebas de Modelos

## Benchmarks de 7B/8B y Small

Para documentar consumo, latencia y calidad, se probarán los siguientes modelos locales:

| Modelo       | Parámetros | Cuantización | Caso de Uso                                                           |
|--------------|------------|--------------|-----------------------------------------------------------------------|
| Gemma 2 2B   | 2,6B       | Q4_K_M       | <b>Prueba de Fluidez:</b> Ideal para equipos con 8GB de RAM.          |
| Phi-3.5 Mini | 3,8B       | Q4_K_M       | <b>Prueba de Lógica:</b> Alta inteligencia en formato ultra-compacto. |
| Llama 3.1 8B | 8,0B       | Q4_0         | <b>Prueba de Límite:</b> Evaluar respuesta del i5 ante carga máxima.  |

## Métricas de Evaluación

### Consumo de RAM

Medición del impacto en el sistema durante la inferencia activa.

### Latencia (TTFT)

Segundos hasta la primera palabra generada por el modelo.

### Calidad Percibida

Capacidad de razonamiento y seguimiento de instrucciones en español.

## 4. Offline Vibe Coding

El objetivo es transformar mi proyecto en una herramienta de desarrollo **autónoma**, eliminando dependencias externas y maximizando la privacidad y productividad:



### Privacidad Total

Los datos nunca salen del equipo local. Sin telemetría, sin APIs externas, sin exposición de código.



### Productividad sin Conexión

Eliminación de la dependencia de APIs externas y los costes asociados a su uso.




### Latencia Cero de Red

Inferencia directa en local para un flujo de trabajo síncrono, privado y sin interrupciones.

# 5. Conclusión Estratégica

El hardware actual es apto para IA local siempre que se utilicen modelos **cuantizados** y escalados a la memoria disponible. La implementación de **Ollama** como puente permitirá que la arquitectura de Ge-mini actual (*Clean Architecture*) integre el soporte local de manera inmediata.

✓ **Veredicto:** El entorno es viable. Con la estrategia de cuantización correcta y los modelos adecuados (2B–4B), Ge-mini puede operar completamente en local, de forma estable y privada.



## Próximos Pasos

1. Instalar Ollama y configurar el servicio en `localhost:11434`.
2. Descargar y testear Gemma 2 2B y Phi-3.5 Mini en LM Studio.
3. Ejecutar benchmark de Llama 3.1 8B para evaluar el límite del hardware.
4. Integrar el endpoint local en la arquitectura de Ge-mini.
5. Documentar resultados de latencia, RAM y calidad percibida.